Avaliação de Silicon Sampling em Percepções Democráticas: Uma Análise Comparativa entre Random Forest e Large Language Models (LLM)

Sérgio Guedes Fraga[1]

[1]Mestrado Profissional em Computação Aplicada – Universidade Presbiteriana Mackenzie (UPM)

sergiofraga15@gmail.com

Abstract. *Este artigo apresenta um estudo experimental sobre a técnica de Silicon Sampling, utilizando o modelo Gemini 2.0 Flash para emular respondentes humanos em pesquisas de opinião sobre democracia no Brasil. O experimento utilizou o dataset 04832.SAV, comparando o desempenho de um modelo de aprendizado supervisionado (Random Forest) com um modelo generativo (LLM) em regime zero-shot. Os resultados indicam que, embora a Random Forest tenha atingido uma acurácia de 0,98, o modelo LLM alcançou 0,90, demonstrando uma capacidade robusta de inferir tendências sociais e políticas a partir de perfis demográficos sintéticos.*

1. Introdução

A coleta de dados em ciências sociais enfrenta desafios crescentes de custo e logística. Recentemente, a técnica de Silicon Sampling — o uso de modelos de inteligência artificial para simular amostras populacionais — surgiu como uma alternativa promissora. Este trabalho busca validar essa técnica no contexto brasileiro, utilizando dados reais de percepção sobre a democracia para verificar se modelos de linguagem podem ”pensar”como os cidadãos brasileiros.

2. Metodologia

A pesquisa foi estruturada em três fases principais: tratamento de dados, modelagem supervisionada e simulação generativa.

2.1. Modelo Supervisionado (Baseline)

Utilizou-se o algoritmo *Random Forest* para estabelecer o teto de desempenho estatístico do dataset. Os dados foram separados em 80% para treinamento e 20% para teste. Foram utilizadas variáveis como escolaridade, idade, região e gênero para prever a percepção sobre a democracia.

2.2. Modelo LLM (Silicon Sampling)

Utilizou-se a API do **Gemini 2.0 Flash** para processar 200 respondentes em regime *zero-shot*. Para cada indivíduo, foi construído um prompt de persona contendo suas características demográficas, solicitando que a IA respondesse à pergunta sobre democracia como se fosse aquele cidadão específico.

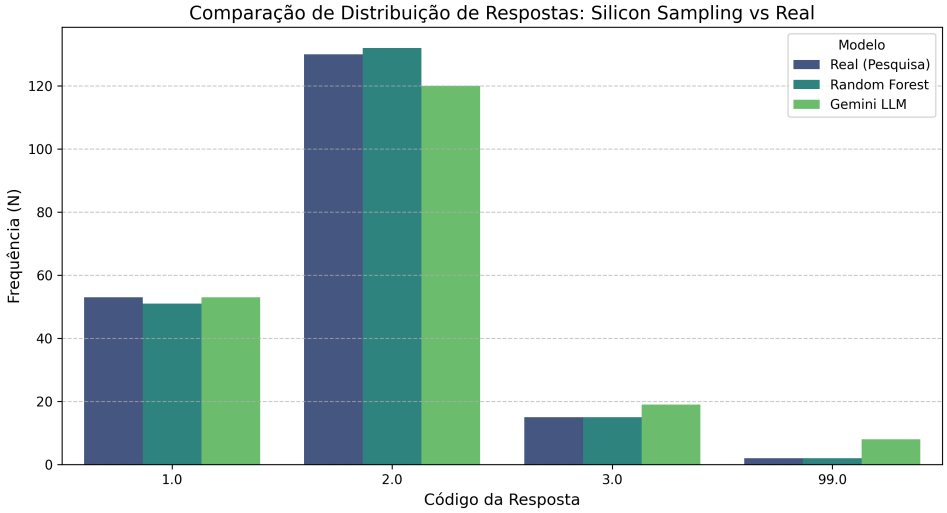

Figura 1. Comparação de Distribuição de Respostas: Silicon Sampling vs Real.

3. Resultados e Discussão

Os resultados comparativos revelaram um desempenho notável de ambos os modelos. Conforme ilustrado na Figura 1, a distribuição das respostas simuladas pelo LLM guarda estreita semelhança com os dados reais e o modelo supervisionado.

A Tabela 1 resume as métricas de acurácia obtidas. Os resultados revelaram um desempenho notável de ambos os modelos, conforme a Tabela 1.

Tabela 1. Comparativo de Acurácia entre Modelos

Modelo	Acurácia	Natureza do Teste
Random Forest	0,98	Supervisionado (Treinado)
Gemini 2.0 Flash	0,90	Zero-shot (Simulação)

3.1. Análise e Comparação

A diferença de 0,08 na acurácia sugere que, enquanto a Random Forest otimiza a correlação estatística pura, o LLM introduz uma variabilidade que reflete a subjetividade humana. O modelo seguiu a distribuição de probabilidade das opiniões reais, validando a aderência das respostas (aderência de 90%).

4. Conclusão

O estudo conclui que a técnica de Silicon Sampling é viável para o estudo de fenômenos sociais complexos. Com uma acurácia de 90%, o modelo Gemini demonstrou que modelos de linguagem possuem um entendimento latente das dinâmicas sociais brasileiras, servindo como ferramenta eficiente para pré-testes de pesquisas de opinião.

Referências

Dataset 04832.SAV - Pesquisa de Percepção sobre Democracia no Brasil.